

DATA SCIENCE PORTFOLIO

A I 驅動的跨領域 情報自動化系統

⊕ 單次執行過濾 86% 無效雜訊，精準鎖定高價值商業情報

整合 Google Gemini 語意理解與堅韌爬蟲架構的
Python 全自動化解決方案

簡報人：王譽鈞

痛點與挑戰：資訊雜訊與資料清理的困境



資訊超載

每日面對數萬條非結構化數據，人工篩選耗時且易錯，難以捕捉轉瞬即逝的 Alpha 情報。



時間陷阱

來源網站大量使用 "2天前" 相對時間，導致歷史回測與長期趨勢分析出現嚴重偏差。



語意雜訊

關鍵字匹配缺乏語境（如 "Apple" 指水果還是科技？），傳統規則式爬蟲無法有效區分。

系統邏輯架構：端到端自動化流水線

Process Flow



工程技術亮點：對抗髒資料的三大防線

Python Engineering

Yahoo 時間校正

針對「2天前」模糊時間，實作 JSON-LD 結構化數據解析。

✓ 修正 166 則日期錯誤

刪 104 則偽裝舊聞

Google RSS 代理

開發 RSS 代理模組，突破 ETtoday 等網站的站內搜尋頻率限制。

稳定的即時索引

0% IP Ban Rate

多執行緒平行架構

實作 4 Threads 平行架構，在有限運算資源下達成最佳 I/O 平衡。

1,300+ 則 / 10 min

效能提升 500%

AI 賦能 I：趨勢獵人 (Trend Hunter)

Generative AI

從「靜態關鍵字」自動轉化為「動態商業場景」，擴展情報視野。



AI 賦能 II：嚴格守門員 (Strict Gatekeeper)

Semantic Filter

AI 成功攔截的真實雜訊案例，精準區分「字面符合」與「語意相關」。

搜尋關鍵字	爬取到的標題	AI 決策	商業洞察 / 攔截原因
OpenAI	「馬斯克談 Grok5 的未來展望...」	REJECT	🚫 競品動態 (非本體)
黃金價格	「陽明海運獲頒環保 金級獎 肯定」	REJECT	A 形容詞誤判
鴻海	「全球 海運 聯盟即將進行重組」	REJECT	🚢 領域錯置 (航運業)
台積電	「台積電 CoWoS 產能擴充計畫提早」	ACCEPT	⌚ 高價值情報

商業影響力：情報密度漏斗

Data Funnel



▼ 總雜訊過濾率達 **86%**，審閱時間 **4hr** → **15min**

⚠ 測試場景：

科技趨勢(輝達/OpenAI/鴻海) x 品牌(星巴克/好市多/特斯拉) x 金融(BTC/黃金/00940)

⌚ 執行數據：

2025/11/26 (回推3日)

作品展示與未來展望

1. 自動化報表 Deliverable

目前系統已能自動生成結構化 Excel 報表，包含來源、校正後日期、AI 摘要與信心評分。使用者可直接透過篩選器查看高價值情報。

2. Next Step: RAG 整合

未來將導入檢索增強生成 (RAG) 技術，建立企業專屬知識庫，允許使用者進行自然語言問答：

User: "上週特斯拉的主要競爭對手動態為何？"

Bot: "根據情報庫，BYD 發布了新的刀片電池技術..."

